智慧電表
異常用電偵測系統

基於非監督式機器學習的AIoT 電力異常分析

組員
4112056045 資工三 莊明達
4112056048 資工三 鄭仲軒
4112064213 電資三 戴煦

組別:1 · 課程:AIoT · 指導老師:陳煥老師 · 2026

大綱

第一章

動機

問題背景與痛點說明

第二章

相關研究

文獻回顧與方法比較

第三章

系統設計

架構圖與規格說明

第四章

結論

總結與未來展望

我們想解決的問題:異常用電中的「竊電」偵測

- 竊電佔電力非技術性損失 (Non-Technical Lost, NTL) 超過九成[1]
- Non-Technical Lost 造成的負面影響[2]:
  1. 電力用戶需要付更多電費
  2. 浪費高額的政府補貼
  3. 造成公共安全疑慮(如透過危險的連接方式竊電)
- 智慧電表雖普及, 但無「分析異常的功能」

[1] https://en.wikipedia.org/wiki/Electricity_theft
[2] https://www.prnewswire.com/news-releases/96-billion-is-lost-every-year-to-electricity-theft-300453411.html

第一章　動機 Motivation

~$101.2B

根據Northeast Group研究
全球一年非技術性損失金額
（2021年，138個國家）[3]

~數日至月

人工抄表、檢查資料之滯後性

~423萬具

台灣安裝智慧電表數 [4]
人工無法處理海量數據

[3] https://northeast-group.com/2021/10/20/electricity-theft-non-technical-losses/
[4] https://www.ctee.com.tw/news/20260407700101-439901

第一章　動機 Motivation

動機 | 相關研究 | 系統設計 | 結論

~$101.2B

根據Northeast Group研究
全球一年非技術性損失金額
（2021年，138個國家）[3]

~數日至月

人工抄表、檢查資料之滯後性

~423萬具

台灣安裝智慧電表數 [4]
人工無法處理海量數據

傳統方式的問題流程

人工抄表（每月一次） → 發現異常（延遲數週） → 人工稽查（成本高昂） → 損失已擴大（難以追回）

[3] https://northeast-group.com/2021/10/20/electricity-theft-non-technical-losses/
[4] https://www.ctee.com.tw/news/20260407700101-439901

第一章　動機 Motivation

動機 | 相關研究 | 系統設計 | 結論

~$101.2B

根據Northeast Group研究
全球一年非技術性損失金額
（2021年，138個國家）[3]

~數日至月

人工抄表、檢查資料之滯後性

~423萬具

台灣安裝智慧電表數 [4]
人工無法處理海量數據

傳統方式的問題流程

人工抄表（每月一次） → 發現異常（延遲數週） → 人工稽查（成本高昂） → 損失已擴大（難以追回）

我們的目標：利用 AI 即時偵測海量數據中的異常，大幅提高即時性、降低人工成本

[3] https://northeast-group.com/2021/10/20/electricity-theft-non-technical-losses/
[4] https://www.ctee.com.tw/news/20260407700101-439901

異常檢測方法比較一覽表

研究者(年份)	使用方法	需要標記？	硬體需求？
Jokar et al. (2016) [4]	CPBETD (SVM + k-Means)	需要	低
Buzau et al. (2020) [5]	HNN-NTL (LSTM + MLP → Sigmoid)	需要	高
Oprea et al. (2021) [6]	SR-CNN + GBM	不需要	高

[4] Jokar, P., Arianpoo, N., & Leung, V. C. (2015). Electricity theft detection in AMI using customers' consumption patterns. IEEE Transactions on Smart Grid, 7(1), 216-226.
[5] Buzau, M. M., Tejedor-Aguilera, J., Cruz-Romero, P., & Gómez-Expósito, A. (2019). Hybrid deep neural networks for detection of non-technical losses in electricity smart meters. IEEE Transactions on Power Systems, 35(2), 1254-1263.
[6] Oprea, S. V., Bâra, A., Puican, F. C., & Radu, I. C. (2021). Anomaly detection with machine learning algorithms and big data in electricity consumption. Sustainability, 13(19), 10963.

第二章 相關研究 Related Work

異常檢測方法比較一覽表

研究者(年份)	使用方法	需要標記？	硬體需求？
Jokar et al. (2016) [4]	CPBETD (SVM + k-Means)	需要	低
Buzau et al. (2020) [5]	HNN-NTL (LSTM + MLP → Sigmoid)	需要	高
Oprea et al. (2021) [6]	SR-CNN + GBM	不需要	高
本專題	**Isolation Forest**	不需要	低

🎯 核心洞見:有標記的資料難以取得； Edge Computing有硬體限制。本專題對此設計解決方案。

[4] Jokar, P., Arianpoo, N., & Leung, V. C. (2015). Electricity theft detection in AMI using customers' consumption patterns. IEEE Transactions on Smart Grid, 7(1), 216-226.
[5] Buzau, M. M., Tejedor-Aguilera, J., Cruz-Romero, P., & Gómez-Expósito, A. (2019). Hybrid deep neural networks for detection of non-technical losses in electricity smart meters. IEEE Transactions on Power Systems, 35(2), 1254-1263.
[6] Oprea, S. V., Bâra, A., Puican, F. C., & Radu, I. C. (2021). Anomaly detection with machine learning algorithms and big data in electricity consumption. Sustainability, 13(19), 10963.

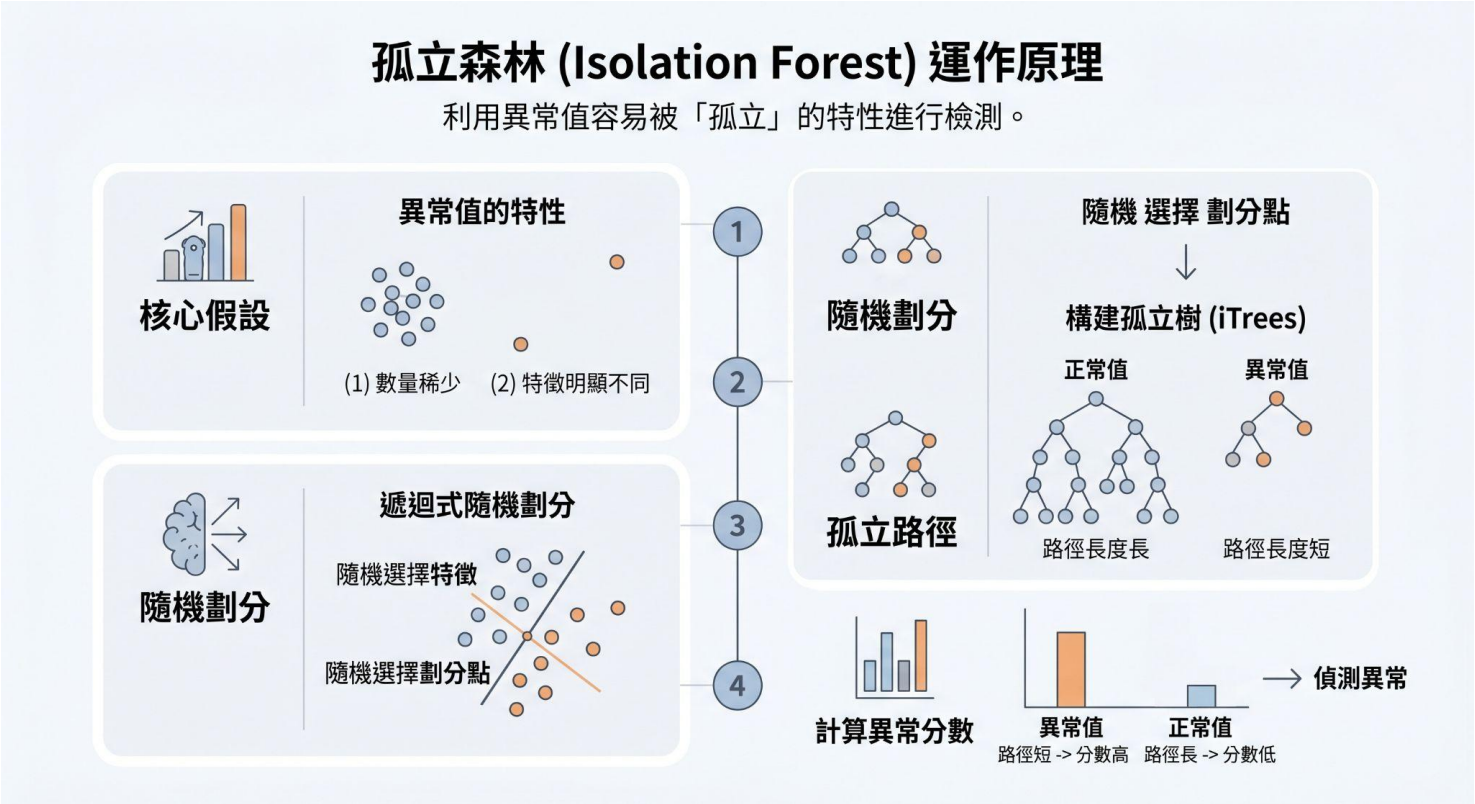
孤立森林 (Isolation Forest) 運作原理
利用異常值容易被「孤立」的特性進行檢測。
核心假設
異常值的特性
(1) 數量稀少
(2) 特徵明顯不同
隨機劃分
遞迴式隨機劃分
隨機選擇特徵
隨機選擇劃分點
1
2
3
4
隨機劃分
隨機 選擇 劃分點
構建孤立樹 (iTrees)
孤立路徑
正常值
異常值
路徑長度長
路徑長度短
計算異常分數
異常值
路徑短 -> 分數高
正常值
路徑長 -> 分數低
偵測異常

第三章　系統設計 Proposed Design

資料層
Data Layer

1 INPUT UCI 電力資料集

- 3-400多戶用電資料

第三章　系統設計 Proposed Design

資料層 Data Layer

1 INPUT UCI 電力資料集

- 3-400多戶用電資料

運算層 Processing Layer

2 PROCESS 資料前處理

- seed固定確認reproducibility
- Lag、Rolling Statistics等特徵工程

3 VALIDATE 合成異常注入

- 依據Jokar et al.描述的方法注入異常資料

4 AI MODEL 模型訓練與偵測

- 非監督式:模型無須真正標記
- 路徑短 ↔ 易被隔離 ↔ 異常

第三章　系統設計 Proposed Design

資料層 Data Layer

1 INPUT UCI 電力資料集

- 3-400多戶用電資料

運算層 Processing Layer

2 PROCESS 資料前處理

- seed固定確認reproducibility
- Lag、Rolling Statistics等特徵工程

3 VALIDATE 合成異常注入

- 依據Jokar et al.描述的方法注入異常資料

4 AI MODEL 模型訓練與偵測

- 非監督式:模型無須真正標記
- 路徑短 ↔ 易被隔離 ↔ 異常

應用層 App Layer

5 OUTPUT Streamlit輸出

- 異常點即時標示於時序圖
- 可匯出異常事件 Log 供後續稽查使用

第四章 結論 Conclusion

✅ 系統架構完整性

成功整合從UCI 電力資料層到Streamlit 應用層的端對端架構。透過非監督式AI 模型訓練，實現無需標記的異常偵測流程。

🚀 偵測效率與可視化

模型具備快速隔離異常路徑之特性，並能將結果即時標示於時序圖中，顯著提升電力數據稽查的直觀性與效率。

🌟 未來展望 Future Work

- 特徵工程優化：引入更多外部變數（如天氣、節慶）提升預測準確度。
- 模型部署優化：在真實邊緣設備上實際測試，確認可行性。

感謝聆聽